Cours de système

La mémoire

Sébastien Paumier / Sylvain Cherrier

Types de mémoires

- plusieurs types de mémoires
- le coût augmente avec la vitesse d'accès, et la capacité de stockage diminue
  - registres du processeur
  - mémoire cache
  - mémoire centrale
  - disques

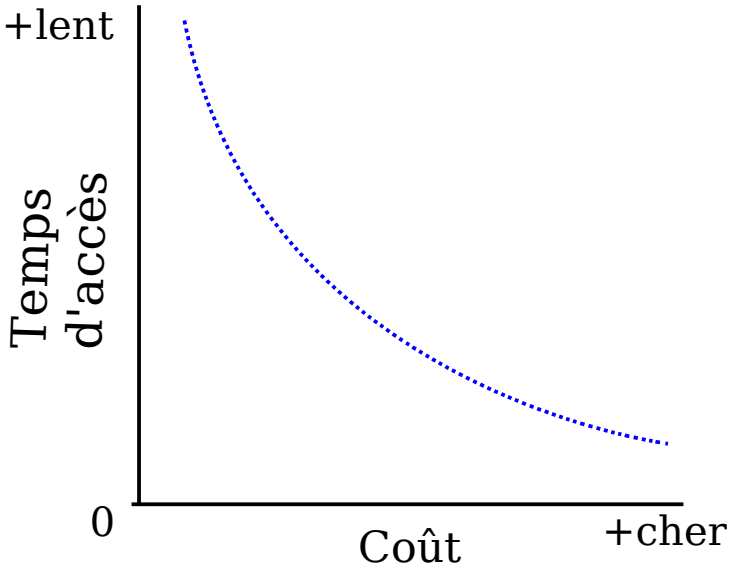

Les registres

- en dur dans le processeur
- modifiables par programme, mais pas tous sans privilège
- certains registres ne peuvent être modifiés en mode utilisateur

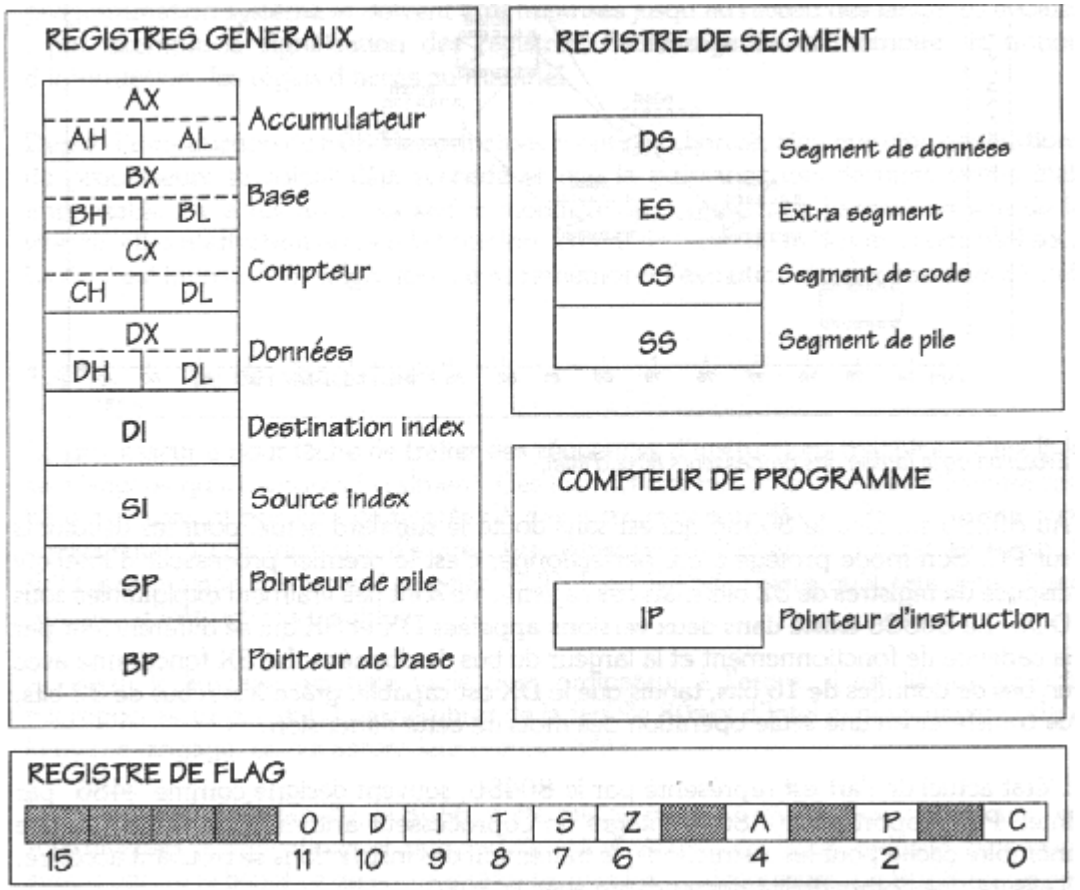

Image : michel.hubin

(i.e. le 12-13 qui indique qu'on est dans ce mode)

Le processeur

- Chargé des calculs (UAL)
- Transfert vers/depuis la mémoire
- Pilotage des périphériques via le bus de commande
- Stockage de quelques valeurs pour manipulation (registres)
- Suivi de l'execution du programme (compteur ordinal)

Le processeur

D'après http://www.samomoi.com

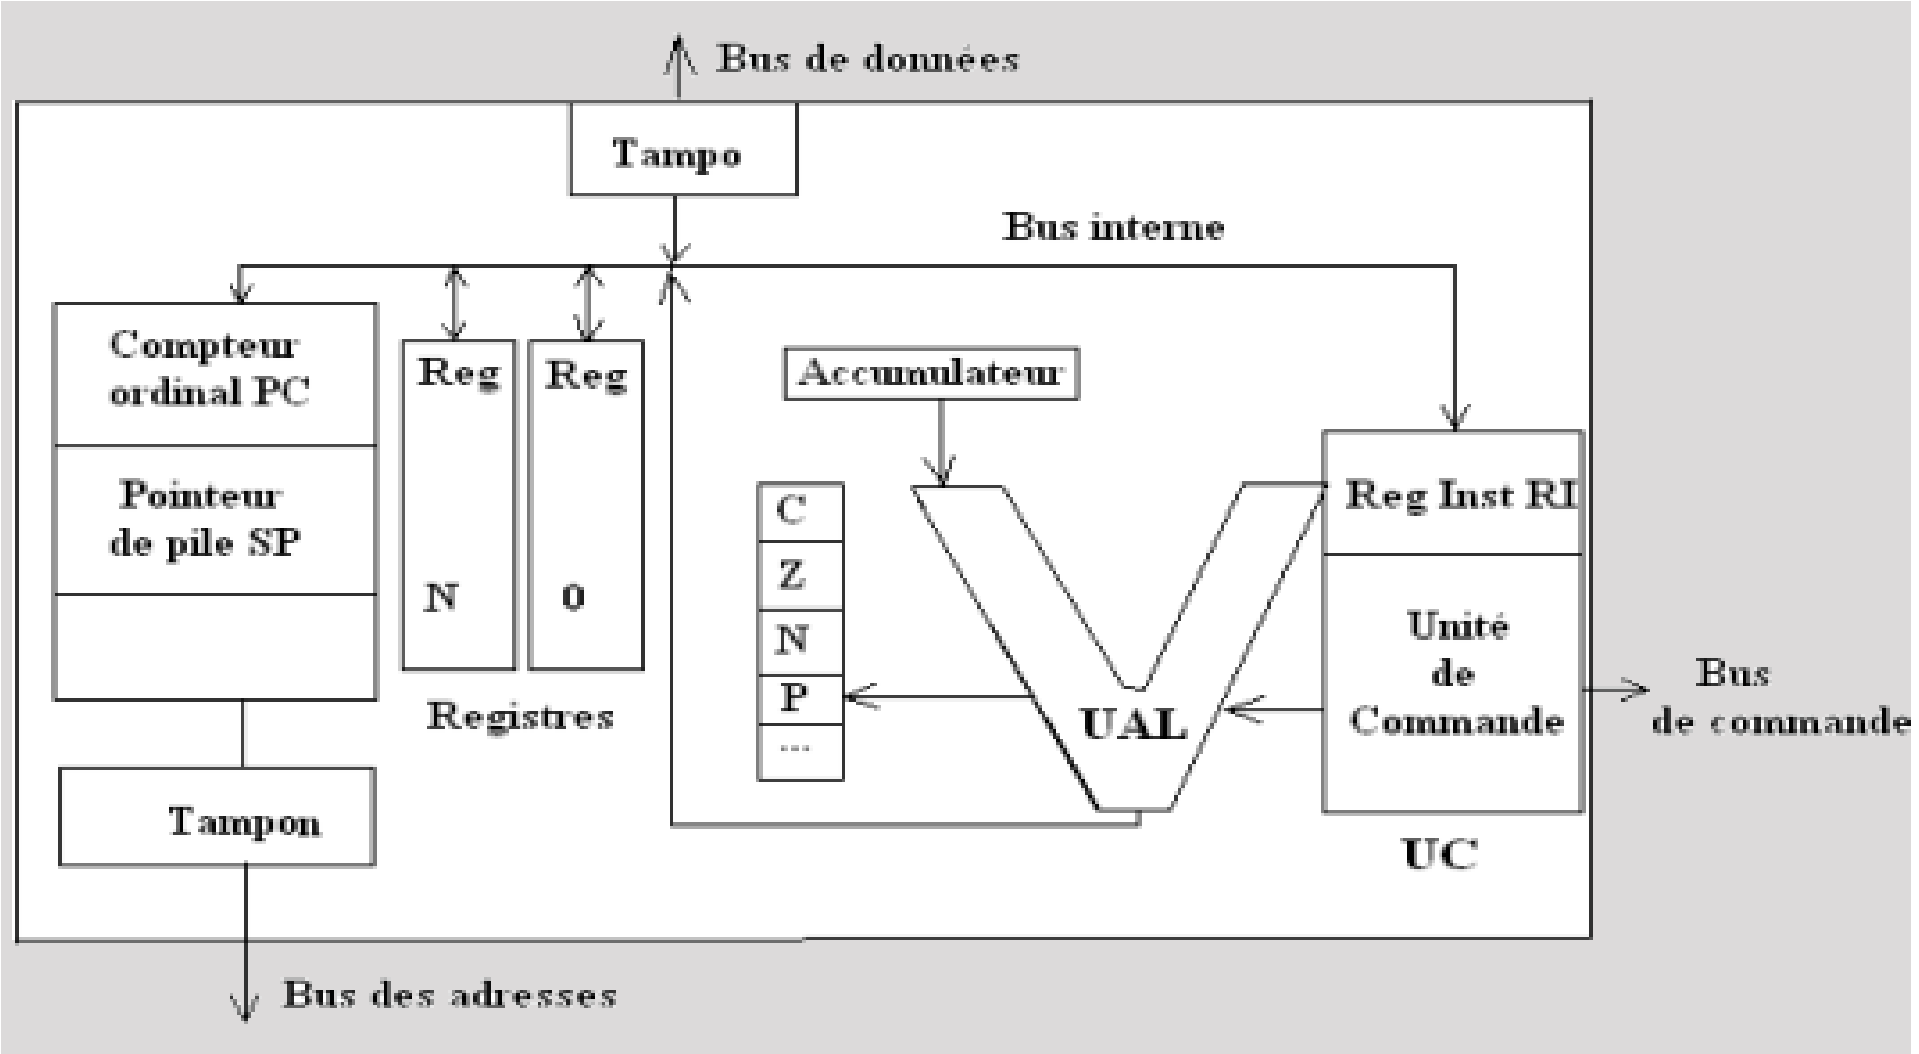

Le cache

- petite mémoire très rapide servant de buffer entre le processeur et un matériel (mémoire centrale, disques, ...)
- exemple: travailler avec des variables locales stockées en cache est beaucoup plus rapide que de faire des allers-retours dans la mémoire centrale

Le cache

- Différentes tailles
- Différentes vitesses d'accès
- Différente proximité du processeur
- Specialisation possible (données, instructions)

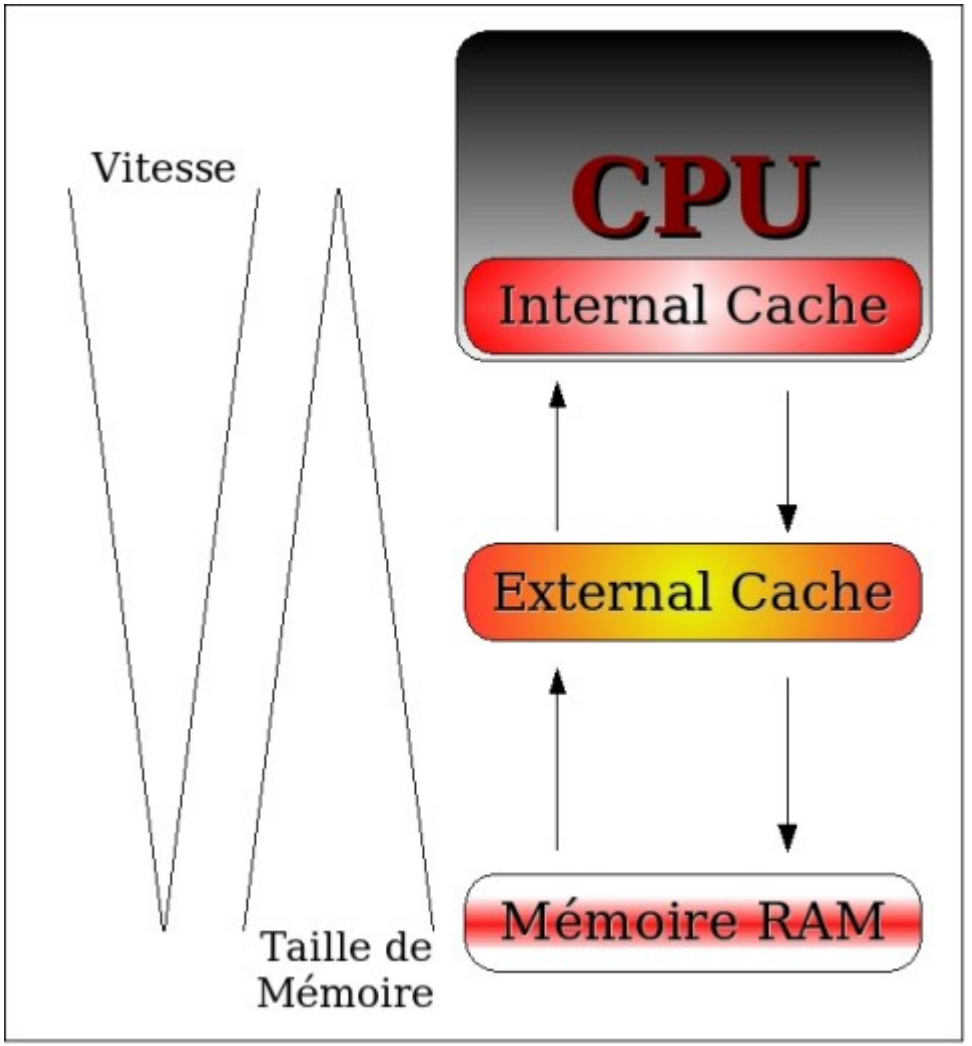

La mémoire centrale

- grand tableau d'octets
- vue comme telle par le processeur
- composant central d'un ordinateur, car c'est par elle que le CPU communique avec le matériel
- au système de protéger la mémoire pour éviter que des programmes fassent n'importe quoi

Allocation contiguë

- les stratégies d'allocation ont beaucoup évolué avec le temps
- technique basique: allocation contiguë
  - on attribue à chaque processus une zone de la mémoire physique
- sur les machines primitives, aucune protection:
  - un programme pouvait écrire n'importe où, y compris sur son code ou celui du système!!

Protection par barrière

- le degré 0 de la protection: empêcher de toucher à la mémoire système
- idée:
  - mettre le système au début de la mémoire
  - utiliser un registre barrière pour vérifier la légalité des accès mémoire des programmes

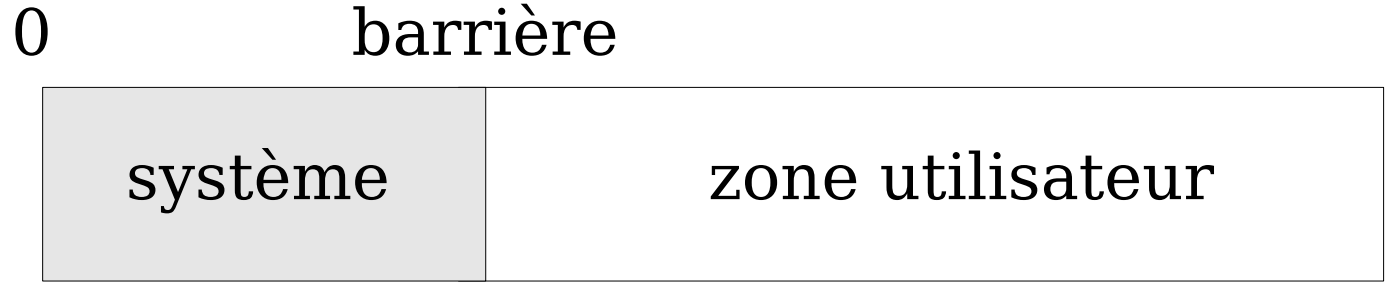

Protection par barrière

- inconvénients:
  - ne protège que le système
  - pas les processus entre eux
  - interdit certaines adresses aux processus
- 2e idée: utiliser un registre *base* qui va s'ajouter aux adresses commençant à 0

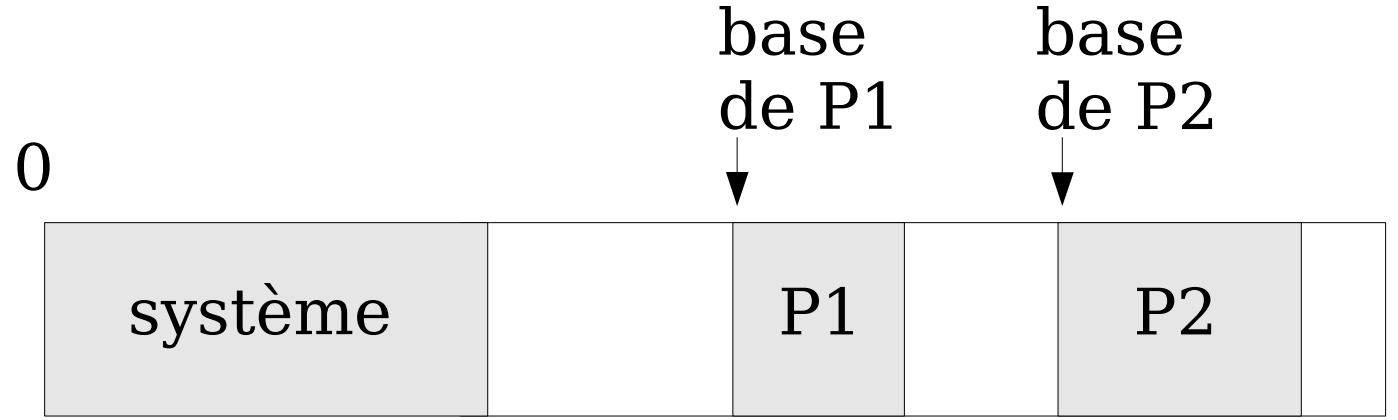

Protection par barrière

- les processus ne sont toujours pas protégés entre eux
- pour ça, il faut un autre registre qui donne, en plus de la base, la *limite* de la zone mémoire
- grâce au mode protégé, on peut alors faire respecter les zones par les processus

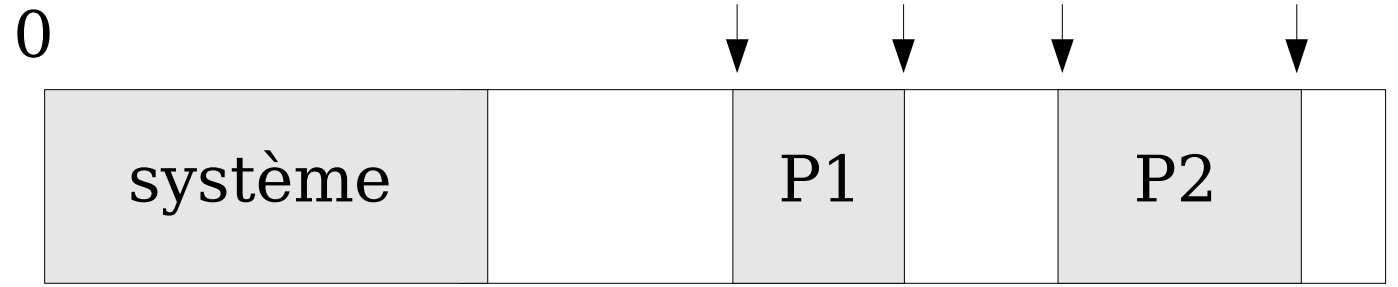

Le swap

- problème: soit on n'utilise pas plus que la mémoire disponible, soit on doit pouvoir enlever et remettre des processus en mémoire
- principe du swap

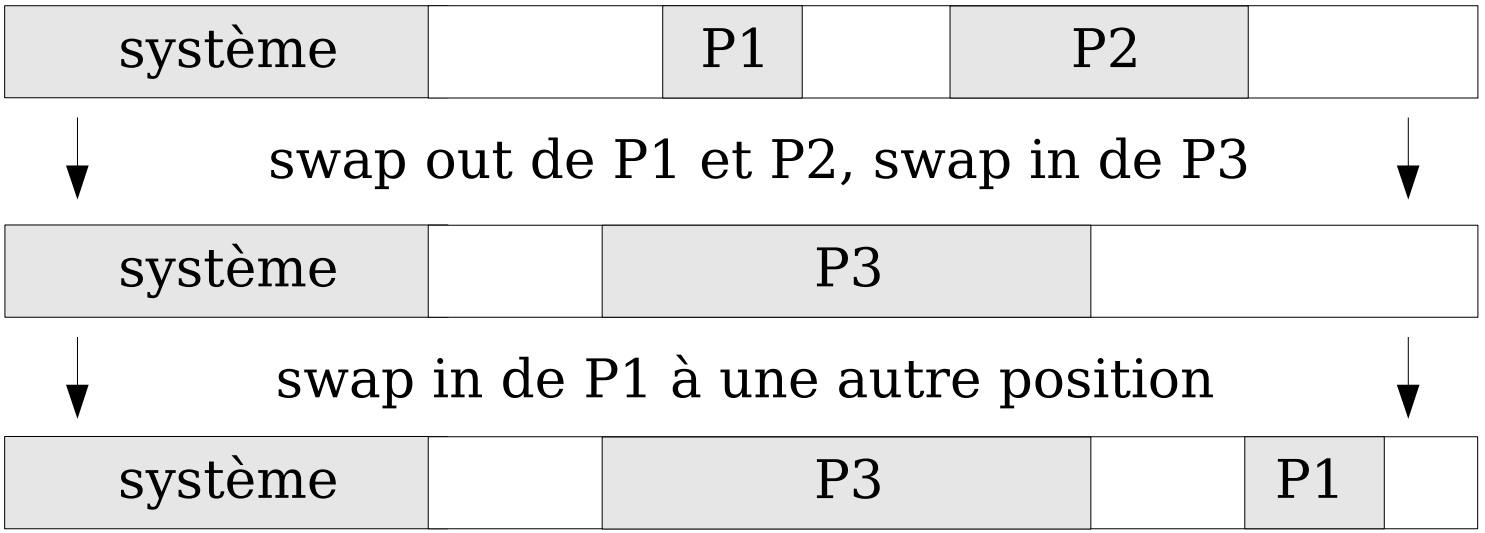

Le swap

- inconvénient: ça coûte très cher en E/S
- possibilité d'amélioration en ne swappant pas tout, mais juste le strict nécessaire
- pour ça, il faut connaître à tout instant la taille de tous les processus:
  - possible si tous les changements de taille se font via un appel système (**sbrk**)
- mais chaque processus doit garder longtemps le processeur pour que ça puisse valoir le coup

Swap et E/S

- si on swappe un processus en attente d'une E/S, les données seront peut-être lues ou écrites dans une zone utilisée par un autre processus
- solution 1: pas de swap pendant une E/S
- solution 2: utiliser des buffers du noyau en recopiant ensuite au bon endroit après le swap

Allocation non contiguë

- même avec le swap, on doit avoir les processus entiers en mémoire
  - peu de processus peuvent cohabiter
  - impossible d'avoir des processus plus grands que la mémoire physique
  - l'ordonnancement devient très critique!!
- remarque: un processus n'a jamais besoin de toute sa mémoire tout le temps
- idée: ne lui donner que ce dont il a besoin à un instant t

Allocation non contiguë

- pour ça, on découpe la mémoire en *pages*
- chaque adresse est composée d'un couple (n° de page,adresse dans la page)
  - translation d'adresses par la MMU
- on peut donc associer à un processus un ensemble non contigu de pages de taille fixe qui seront plus faciles à allouer et à swapper
- le système n'a plus qu'à tenir à jour une table des pages

Table des pages

- il faut savoir quelles pages sont occupées et à quels processus elles appartiennent
- mécanisme de protection des pages qui permet par exemple de partager une page de code entre plusieurs processus (il suffit de la protéger en écriture)
- le rôle du système est de fournir les pages quand les processus en ont besoin

Mémoire virtuelle

- rien n'empêche de manipuler plus de pages qu'il ne peut en tenir en mémoire
  - principe de la mémoire virtuelle
- pagination à la demande:
  - si un processus demande une adresse dans une page absente de la mémoire, le processeur génère une page fault
  - le système charge la page demandée et redonne la main au processus
  - nécessite peut-être de supprimer une autre page

Mémoire virtuelle

- comme il y a des accès disque, c'est lent
- il faut minimiser les fautes de pages pour éviter de vampiriser le système
- le système: choisir au mieux les pages à avoir en mémoire
- le programmeur: ne pas parcourir la mémoire n'importe comment

```
arch/x86/mm/fault.c: do_page_fault
mm/memory.c : do_no_page
```

Outils pour la surveillance

- Top ou htop (VIRT RES SHR)

root@ilium: ~

```
  1  [||||                                    7.1%]     Tasks: 136, 365 thr, 60 kthr; 2 running
  2  [|||||                                  10.1%]     Load average: 0.16 0.17 0.21
  Mem[||||||||||||||||||||||||||||||1587/3953MB]     Uptime: 02:16:44
  Swp[|                                     0/3812MB]

  PID USER      PRI  NI  VIRT   RES   SHR S CPU% MEM%   TIME+  Command
 3797 sylvain    20   0 1351M  129M 53764 S  4.4  3.3  3:05.09 compiz
 7456 root       20   0 26064  2436  1464 R  2.5  0.1  0:07.78 htop
 1523 root       20   0  239M 70028 30932 S  1.9  1.7  5:06.17 /usr/bin/X -core :0 -auth /var/run/lightdm
 7573 sylvain    20   0  708M 15888 12248 S  1.3  0.4  0:00.15 /usr/lib/gimp/2.0/plug-ins/screenshot -gim
 7303 sylvain    20   0  415M 35668 23892 S  0.6  0.9  0:05.81 /usr/lib/firefox/plugin-container /usr/lib
 5948 sylvain    20   0 1303M  408M 52432 S  0.6 10.3  4:09.40 /usr/lib/firefox/firefox
 3544 sylvain    20   0  349M 12120  5120 S  0.0  0.3  0:01.47 /usr/lib/x86_64-linux-gnu/hud/hud-service
 3611 sylvain    20   0  544M 13488  8496 S  0.0  0.3  0:00.66 /usr/lib/x86_64-linux-gnu/bamf/bamfdaemon
 4131 sylvain    20   0 1351M  129M 53764 S  0.0  3.3  0:00.96 compiz
   15 root       20   0     0     0     0 R  0.0  0.0  0:00.88 rcuos/1
 3599 sylvain    20   0  628M 14216  9456 S  0.0  0.4  0:01.97 /usr/lib/ibus/ibus-ui-gtk3
 3605 sylvain    20   0  628M 14216  9456 S  0.0  0.4  0:00.94 /usr/lib/ibus/ibus-ui-gtk3
F1Help  F2Setup F3SearchF4FilterF5Tree  F6SortByF7Nice -F8Nice +F9Kill  F10Quit
```

Outils pour la surveillance

- Ps aux (VSZ virtual size, RSS resident size)

sylvain@ilium: ~/Université/C - Système/Cours Systeme SB/kernel_0

```
sylvain@ilium:~/Université/C - Système/Cours Systeme SB/kernel_0$ ps aux
USER        PID %CPU %MEM    VSZ   RSS TTY      STAT START   TIME COMMAND
root          1  0.0  0.0  27224  2844 ?        Ss   10:22   0:01 /sbin/init
root          2  0.0  0.0      0     0 ?        S    10:22   0:00 [kthreadd]
root          3  0.0  0.0      0     0 ?        S    10:22   0:00 [ksoftirqd/0]
root          5  0.0  0.0      0     0 ?        S<   10:22   0:00 [kworker/0:0H]
root          7  0.0  0.0      0     0 ?        S    10:22   0:00 [migration/0]
root          8  0.0  0.0      0     0 ?        S    10:22   0:00 [rcu_bh]
root          9  0.0  0.0      0     0 ?        S    10:22   0:00 [rcuob/0]
root         10  0.0  0.0      0     0 ?        S    10:22   0:00 [rcuob/1]
root         11  0.0  0.0      0     0 ?        S    10:22   0:00 [rcuob/2]
root         12  0.0  0.0      0     0 ?        S    10:22   0:00 [rcuob/3]
root         13  0.0  0.0      0     0 ?        S    10:22   0:02 [rcu_sched]
root         14  0.0  0.0      0     0 ?        S    10:22   0:00 [rcuos/0]
root         15  0.0  0.0      0     0 ?        S    10:22   0:00 [rcuos/1]
root         16  0.0  0.0      0     0 ?        S    10:22   0:00 [rcuos/2]
root         17  0.0  0.0      0     0 ?        S    10:22   0:00 [rcuos/3]
root         18  0.0  0.0      0     0 ?        S    10:22   0:00 [watchdog/0]
root         19  0.0  0.0      0     0 ?        S    10:22   0:00 [watchdog/1]
root         20  0.0  0.0      0     0 ?        S    10:22   0:00 [migration/1]
root         21  0.0  0.0      0     0 ?        S    10:22   0:00 [ksoftirqd/1]
root         23  0.0  0.0      0     0 ?        S<   10:22   0:00 [kworker/1:0H]
root         24  0.0  0.0      0     0 ?        S<   10:22   0:00 [khelper]
root         25  0.0  0.0      0     0 ?        S    10:22   0:00 [kdevtmpfs]
```

Outils pour la surveillance

- Vmstat (si so swap in swap out)

sylvain@ilium: ~/Université/C - Système/Cours Systeme SB/kernel_0

```
sylvain@ilium:~/Université/C - Système/Cours Systeme SB/kernel_0$ vmstat 5 10
procs -----------memory---------- ---swap-- -----io---- -system-- ----cpu----
 r  b   swpd   free   buff  cache   si   so    bi    bo   in   cs us sy id wa
 4  0    236 244968 212340 1927676    0    0   424   351  509 1009 14  3 81  2
 3  0    236 214892 212976 1943772    0    0  3321   138 1419 2501 20  8 59 13
 1  0    236 140032 213520 1959620    0    0  3217    26 1453 3004 56  5 26 12
 3  0    236 151872 213848 1909580    0    0  1285   158 1364 3355 50  6 36  7
 3  0    236 142880 213856 1863448    0    0  2238     0 1042 1948 84  5  8  4
 3  2    236 117540 213952 1816008    0    0  1260   141 1334 2287 74  6 12  8
 4  0    236 112388 214620 1788728    0    0  2787    62 1581 2953 52  7 10 31
 0  2    236 126424 212536 1670100    0    0  2656   212 2074 5175 72 11  3 14
 8  2  11440 139888 210148 1578424    0 2241  2250  2541 1879 5390 69 15  1 15
 1  4  17172 148536 209756 1464684    0 1146  2254  1590 1401 2924 89  9  0  2
sylvain@ilium:~/Université/C - Système/Cours Systeme SB/kernel_0$
```

Outils pour la surveillance

- pmap

```
sylvain@ilium: ~/Université/C - Système/Cours Systeme SB/kernel_0
 8570 pts/3    R+     0:00 ps ax
sylvain@ilium:~/Université/C - Système/Cours Systeme SB/kernel_0$ pmap -x 7461
7461:   bash
Address           Kbytes     RSS   Dirty Mode   Mapping
0000000000400000     900     684     224 r-x--  bash
00000000006e0000       4       4       4 r----  bash
00000000006e1000      36      36      36 rw---  bash
00000000006ea000      24      24      24 rw---    [ anon ]
0000000000b06000    1772    1744    1744 rw---    [ anon ]
00007f45e389a000      48      12       0 r-x--  libnss_files-2.17.so
00007f45e38a6000    2044       0       0 -----  libnss_files-2.17.so
00007f45e3aa5000       4       4       4 r----  libnss_files-2.17.so
00007f45e3aa6000       4       4       4 rw---  libnss_files-2.17.so
00007f45e3aa7000      44      16       0 r-x--  libnss_nis-2.17.so
00007f45e3ab2000    2044       0       0 -----  libnss_nis-2.17.so
00007f45e3cb1000       4       4       4 r----  libnss_nis-2.17.so
00007f45e3cb2000       4       4       4 rw---  libnss_nis-2.17.so
00007f45e3cb3000      92      20       0 r-x--  libnsl-2.17.so
```

Remplacement de page

- comment choisir quelle page retirer de la mémoire, pour minimiser les fautes de pages ?
- tests des différents algorithmes pour les données suivantes:
  - 3 pages disponibles en mémoire
  - pages demandées dans l'ordre suivant : 7 0 1 2 0 3 0 4 2 3 0 3 2 1 2 0 1 7 0 1

Remplacement idéal

- retirer la page qui sera inutile le plus longtemps

```
7: 7xx     0: 203
0: 70x     3: 203
1: 701     2: 203
2: 201     1: 201
0: 201     2: 201
3: 203     0: 201
0: 203     1: 201
4: 243     7: 701
2: 243     0: 701
3: 243     1: 701
```

=9 fautes de pages

problème: il faudrait pouvoir prédire l'avenir...

Remplacement FIFO

- retirer la page la plus ancienne

```
7: 7xx     0: 023
0: 70x     3: 023
1: 701     2: 023
2: 201     1: 013
0: 201     2: 012
3: 231     0: 012
0: 230     1: 012
4: 430     7: 712
2: 420     0: 702
3: 423     1: 701
```

=15 fautes de pages

anomalie de Belady: cet algo peut produire plus de fautes de pages quand il y a plus de pages disponibles !!

Remplacement LRU

- Least Recently Used: garder les N-1 pages auxquelles on a accédé en dernier

```
7: 7xx     0: 032
0: 70x     3: 032
1: 701     2: 032
2: 201     1: 132
0: 201     2: 132
3: 203     0: 102
0: 203     1: 102
4: 403     7: 107
2: 402     0: 107
3: 432     1: 107
```

=12 fautes de pages

comme FIFO, nécessite de représenter les dates d'accès aux pages

Remplacement LRU

- plusieurs façons de gérer ces dates
- compteurs:
  - tenir à jour un compteur de temps par page
  - on doit aussi le swapper quand la page change
- pile:
  - mettre la page utilisée en haut de pile
  - le bas de pile désigne celle qui a été utilisée le moins récemment

Remplacement LRU

- masques:
  - chaque page a un octet
  - à chaque accès, on met à 1 le bit de poids fort
  - régulièrement, le système décale tous les octets d'un bit vers la droite
  - l'octet le plus petit correspond ainsi à la page à supprimer (10010111 est plus récent que 00111011)
  - à numéro égal, on prend la première page rencontrée

Algo de la 2ème chance

- chaque page possède un bit qu'on met à 1 quand on y accède
- quand on doit supprimer une page, on regarde ce bit:
  - s'il vaut 0, on supprime la page
  - s'il vaut 1, on met le bit à 0 et on cherche une autre victime

Le dirty bit

- si la page a déjà une copie identique dans le swap, on n'aura pas besoin de la sauver si on la retire de la mémoire
- le dirty bit permet de savoir si une telle économie est possible
- utilisé comme heuristique complémentaire par les algorithmes de remplacement de pages

```
mm/swap.c: mark_page_accessed
mm/page-writeback.c
```

Allocation de pages

- bien choisir sa stratégie:
  - ne pas donner trop de pages à un processus qui les sous-utilise
  - ne pas en donner trop peu pour minimiser les fautes de pages et le swap
- principe du Copy-On-Write:
  - éviter de dupliquer des pages
  - pratique quand on enchaîne un fork et un exec
  - précurseur=vfork (deprecated)

DMA

- Direct Memory Access
- principe: ne pas bloquer le processeur pendant un transfert de données depuis un périphérique
- le CPU initie le transfert
- celui-ci a lieu indépendamment sur le bus DMA
- le CPU est prévenu par interruption quand c'est terminé

Pages empoisonnées

- le matériel peut détecter des erreurs physiques dans la mémoire
- les pages sont marquées "empoisonnées"
  - une page empoisonnée qui a une copie sur disque peut être éliminée
  - si pas de copie, l'application doit être tuée
  - une page empoisonnée ne sera plus jamais utilisée

`mm/memory-failure.c`

Mémoire du noyau

- le noyau doit avoir de la mémoire accessible immédiatement, sans swap
- principe du slab:
  - pré-réserver des buffers de certaines tailles adaptées aux objets courants du noyau (locks, inodes, etc)
  - évite la fragmentation
  - **kmalloc**/**kfree**: trouver vite des slabs disponibles adaptés aux demandes
  - zones mémoire contiguës limitées à 128Ko (cf. **vmalloc**/**vfree** pour plus)

mm/slab.c

Fichiers mappés

- `void *mmap(void *addr, size_t length, int prot, int flags, int fd, off_t offset);`
- permet de mapper en mémoire le contenu d'un fichier
- on accédera au contenu comme à un tableau
- c'est le système qui gère automatiquement les accès disques et les changements de page

mmap

- **addr**: adresse de base à laquelle on veut mapper le fichier; si **NULL**, le noyau choisit
- **length**: taille de la zone à projeter
- **fd**: descripteur du fichier
- **offset**: position de départ dans le fichier

mmap

- **prot**: mode de protection de la zone (OU binaire)
  - PROT_READ: accessible en lecture
  - PROT_WRITE: accessible en écriture
  - PROT_EXEC: accessible en exécution
  - PROT_NONE: inaccessible

mmap

- **flags**:
  - MAP_SHARED: les modifications sont visibles par tous les processus manipulant la zone et sont répercutées dans le fichier sous-jacent (de façon asynchrone)
  - MAP_PRIVATE: chaque processus à sa copie privée grâce au copy-on-write; les modifications ne sont pas répercutées sur le fichier

mmap.cpp

munmap

- `int munmap(void *addr, size_t length);`
- unmappe une zone, en sauvegardant les modifications sur le fichier
- possibilité de demander la synchronisation avec le fichier grâce à

```
int msync(void *addr, size_t length, int flags);
```

madvise

- `int madvise(void *addr, size_t length, int advice);`
- `advice` suggère une politique au noyau:
  - MADV_SEQUENTIAL: les pages vont être lues dans l'ordre et oubliées aussitôt (on peut en précharger)
  - MADV_RANDOM: lecture aléatoire (pas besoin de précharger)
  - etc.

mprotect

- `int mprotect(const void *addr, size_t len, int prot);`
- **prot** demande au noyau de protéger la zone contre la lecture (PROT_READ), l'écriture (PROT_WRITE), l'exécution (PROT_EXEC), ou tout à la fois (PROT_NONE)
- une violation entraînera un SIGSEGV

mprotect.cpp

mlock

- `int mlock(const void *addr,size_t len);`
- `int munlock(const void *addr,size_t len);`
- permet de demander au noyau de ne pas swapper la zone
- utile pour:
  - le temps réel, pour éviter les ralentissements imprévus dûs au swap
  - la sécurité, pour éviter que des données sensibles (mots de passe) se retrouvent dans la zone de swap sur disque

Map anonyme

- avec le flag MAP_ANONYMOUS, on peut demander à **mmap** une zone mémoire qui ne soit pas basée sur un fichier, et sans modifier la taille du processus avec **sbrk**
- grâce à MAP_PRIVATE, on a ainsi une zone qui se duplique correctement à travers **fork**
- utile pour implémenter **malloc**

My malloc

- la variable d'environnement LD_PRELOAD permet de précharger en priorité des bibliothèques
- possibilité de hook sur toutes les fonctions de bibliothèques, y compris la libc
- on alloue de la mémoire au chargement de la bibliothèque et on affiche des statistiques à sa libération

My malloc

- exécution comparée avec valgrind:

mymmalloc.cpp

```
$>LD_PRELOAD=./mymalloc.so ps
…
132 mallocs (3 reallocs, 9 callocs), 197 frees
43392 bytes allocated
441 bytes unfreed
$>valgrind ps
…
==4375== HEAP SUMMARY:
==4375==     in use at exit: 441 bytes in 18 blocks
==4375==   total heap usage: 144 allocs, 126 frees, 43,392
bytes allocated
==4375==
…
```